

Comparação das bases de regras e escolha da base de conhecimento

As três árvores construídas partiram da mesma base de 30 exemplos e do mesmo atributo raiz, Tempo de Emprego, o que já indica que esse atributo é o mais informativo isoladamente, independentemente do critério de divisão adotado. As três bases de regras geradas têm tamanho semelhante: 16 regras no ID3, 15 no C4.5 e 16 no CART, e profundidade parecida. Ou seja, quanto ao tamanho e complexidade, as três são praticamente equivalentes, e a escolha entre elas foi baseada nos critérios de divisão de cada algoritmo.

A principal diferença observada entre as três aparece logo no segundo nível da árvore, no ramo Tempo de Emprego = Menos de 1 ano. O ID3 e o CART escolheram o atributo Renda nesse ponto, Já o C4.5 escolheu Garantia.

Renda tem três valores possíveis, contra apenas dois de Garantia, e por isso é mais favorecida por causa desses dois critérios independentemente do que pelo seu real poder preditivo. O ganho de razão do C4.5 existe justamente para corrigir esse viés, penalizando atributos com muitos valores através do Split Info, o que faz o algoritmo escolher Garantia nesse ponto.

Por esses motivos, a base de conhecimento escolhida como mais apropriada para o problema de análise de risco de crédito é a gerada pelo algoritmo C4.5. Ela tem o mesmo nível de simplicidade das outras duas, mas foi construída com um critério de divisão que corrige um viés conhecido do ganho de informação simples, e essa correção levou a árvore a priorizar um atributo (Garantia) mais coerente com a prática de concessão de crédito discutida em sala. As bases geradas por ID3 e CART não estão erradas, mas refletem um critério mais ingênuo, que nesse caso específico acabou supervalorizando um atributo (Renda) apenas por ele ter mais categorias, não necessariamente por ser o mais relevante.